

Diccionario de datos

Trayectoria de IA: Analítica de Datos

Diplomado de IA para Docentes

Universidad EAFIT

Explorador

basico.csv
3 variables

Integrador

medio.csv
4 variables

Experto

experto.csv
12 variables

Elaborado por Jorge Iván Padilla Buriticá

jipadillab@eafit.edu.co

[linkedin.com/in/jipadilla](https://www.linkedin.com/in/jipadilla)

github.com/jipadillab/Trayectoria_IA_EAFIT

Versión 1.0 • 28 de septiembre de 2026

Índice

1. Introducción	1
1.1. Cómo leer una ficha de variable	1
1.2. Origen de los datos	1
2. Panorama de los archivos	1
2.1. Formato de los archivos	1
3. Convenciones y tipos de variable	2
4. Ruta Explorador: basico.csv	2
5. Ruta Integrador: medio.csv	3
6. Ruta Experto: experto.csv	5
7. Estadísticos de referencia	9
7.1. Variables numéricas	9
7.2. Variables categóricas	9
8. Reglas de coherencia entre variables	9
9. Calidad de los datos y ruido intencional	10
9.1. Ruido intencional en experto.csv	10
10. Cómo clasifica la app cada variable	10
11. Uso responsable de los datos	11
A. Registro de ejemplo	11
B. Glosario	12
C. Autoría y contacto	12

1. Introducción

Este documento es el diccionario de datos del taller *Trayectoria de IA: Analítica de Datos*. Explica, para cada archivo y para cada ruta del taller (Explorador, Integrador y Experto), qué significa cada variable, de qué tipo es, qué valores puede tomar y cómo se usa en el análisis.

1.1. Cómo leer una ficha de variable

Cada variable se describe en una ficha con los mismos campos:

- **Barra de título:** nombre de la variable en el archivo y, a la derecha, su etiqueta legible.
- **Significado:** qué representa.
- **Tipo:** clase de variable (numérica, categórica, texto, identificador).
- **Valores válidos:** escala, unidad o categorías permitidas.
- **Valores observados:** rango o frecuencias reales en los datos.
- **Valores vacíos:** si la variable puede traer celdas sin dato.
- **Uso en esta ruta:** para qué se usa en el análisis de esa ruta.

1.2. Origen de los datos

Los datos fueron generados para este taller con fines pedagógicos. Cada fila representa a un estudiante de una universidad, pero ninguna corresponde a una persona real.

2. Panorama de los archivos

Los tres archivos de las rutas se derivan de un mismo **dataset maestro**: las mismas 200 filas y los mismos identificadores. Cada ruta recibe solo las columnas que necesita, de modo que al comparar resultados todos hablan de los mismos estudiantes.

Archivo	Ruta	Filas	Variables	Contenido
maestro.csv	Referencia	200	12	Dataset completo y sin alteraciones. Base de los demás archivos.
basico.csv	Explorador	200	3	Identificador, nota final y comentario de texto.
medio.csv	Integrador	200	4	Identificador, participación, horario de estudio y nota final.
experto.csv	Experto	200	12	Dataset completo con ruido intencional para practicar limpieza.

2.1. Formato de los archivos

- Archivos CSV con codificación UTF-8, separados por comas y con punto decimal.
- La primera fila contiene los nombres de las columnas.
- Un valor vacío se representa con una celda sin contenido.
- La app también lee archivos con separador punto y coma y con codificación Latin-1.

3. Convenciones y tipos de variable

Tipo	Definición	Ejemplo en los datos
Identificador	Código único de cada registro; no se analiza.	<code>id_estudiante</code>
Numérica continua	Número que puede tomar valores intermedios (decimales).	<code>nota_final</code> , <code>asistencia_pct</code>
Numérica discreta	Conteo: solo valores enteros.	<code>clics_material_extra</code>
Categoría nominal	Categorías sin orden de magnitud.	<code>facultad</code> , <code>horario_estudio</code>
Categoría ordinal	Categorías con un orden lógico.	<code>participacion_clase</code>
Categoría binaria	Solo dos categorías posibles.	<code>uso_tutorias</code>
Texto libre	Texto escrito por una persona, sin categorías fijas.	<code>comentario_retro</code>

Escala de notas

Todas las notas (`nota_corte1`, `nota_corte2` y `nota_final`) usan la escala colombiana de **0.0 a 5.0**, con un decimal.

4. Ruta Explorador: `basico.csv`

Archivo: `basico.csv` (200 filas, 3 variables). **Enfoque:** análisis de texto. Esta ruta se apoya sobre todo en el comentario del estudiante y en la nota final.

Resumen de variables

Variable	Tipo	Valores o rango
<code>id_estudiante</code>	Identificador	E001 a E200
<code>nota_final</code>	Numérica continua	0.0 a 5.0
<code>comentario_retro</code>	Texto libre	Texto breve

Fichas de variables

<code>id_estudiante</code>	Identificador del estudiante
Significado	Código único que identifica cada registro del conjunto de datos. No contiene información personal.
Tipo	Identificador (texto).
Valores válidos	Código de la forma E seguido de tres dígitos, de E001 a E200.
Valores observados	200 valores distintos; ninguno se repite.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Permite identificar cada fila. No se analiza ni se grafica.

nota_final	Nota final
Significado	Calificación definitiva del estudiante. Se calcula como el promedio de <code>nota_corte1</code> y <code>nota_corte2</code> , redondeado a un decimal.
Tipo	Numérica continua.
Valores válidos	Escala de 0.0 a 5.0, con un decimal.
Valores observados	Mínimo 1.5, máximo 5.0, media 3.53, desviación estándar 0.90.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Variable numérica principal. Se describe (promedio, mediana, distribución) en la pestaña 2 · <i>EDA estándar</i> y se usa para separar notas bajas de notas altas con el umbral de la pestaña 3 · <i>Análisis de datos</i> .

comentario_retro	Comentario de retroalimentación
Significado	Texto breve escrito por el estudiante, a mitad de semestre, sobre su experiencia en la materia.
Tipo	Texto libre (español).
Valores válidos	Cualquier texto breve.
Valores observados	Entre 50 y 92 caracteres (promedio 66). Hay 39 textos distintos en 200 registros: algunos comentarios se repiten.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Protagonista de la ruta. Se explora en 2 · <i>EDA estándar</i> (sub-pestaña Texto), se cruza con la nota mediante palabras clave en 3 · <i>Análisis de datos</i> y se interpreta con IA en la pestaña 4 · <i>Análisis con IA</i> .

5. Ruta Integrador: medio.csv

Archivo: medio.csv (200 filas, 4 variables). **Enfoque:** comparar grupos y cruzar variables categóricas con la nota.

Resumen de variables

Variable	Tipo	Valores o rango
<code>id_estudiante</code>	Identificador	E001 a E200
<code>participacion_clase</code>	Categórica ordinal	Nula, Baja, Media, Alta (en ese orden)
<code>horario_estudio</code>	Categórica nominal	Mañana, Tarde, Noche
<code>nota_final</code>	Numérica continua	0.0 a 5.0

Fichas de variables

id_estudiante		Identificador del estudiante
Significado	Código único que identifica cada registro del conjunto de datos. No contiene información personal.	
Tipo	Identificador (texto).	
Valores válidos	Código de la forma E seguido de tres dígitos, de E001 a E200.	
Valores observados	200 valores distintos; ninguno se repite.	
Valores vacíos	No admite vacíos.	
Uso en esta ruta	Permite identificar cada fila. No se analiza ni se grafica.	

participacion_clase		Nivel de participación en clase
Significado	Valoración del nivel de intervención del estudiante en las sesiones de clase.	
Tipo	Categórica ordinal (texto): las categorías tienen un orden lógico.	
Valores válidos	Nula, Baja, Media, Alta (de menor a mayor participación).	
Valores observados	Nula: 38, Baja: 41, Media: 69, Alta: 52 registros.	
Valores vacíos	No admite vacíos.	
Uso en esta ruta	Categoría ordinal de agrupación. Se compara nota_final entre niveles de participación y se cruza con horario_estudio en el mapa de calor de la pestaña 3.	

horario_estudio		Horario de estudio preferido
Significado	Franja del día en la que el estudiante declara estudiar con mayor frecuencia.	
Tipo	Categórica nominal (texto). Las categorías tienen un orden cronológico natural que la app usa solo para ordenar tablas y gráficas.	
Valores válidos	Mañana, Tarde, Noche.	
Valores observados	Mañana: 79, Tarde: 72, Noche: 49 registros.	
Valores vacíos	No admite vacíos.	
Uso en esta ruta	Segunda categoría de agrupación. Se cruza con participacion_clase para detectar combinaciones que se salen del patrón general.	

nota_final	Nota final
Significado	Calificación definitiva del estudiante. Se calcula como el promedio de <code>nota_corte1</code> y <code>nota_corte2</code> , redondeado a un decimal.
Tipo	Numérica continua.
Valores válidos	Escala de 0.0 a 5.0, con un decimal.
Valores observados	Mínimo 1.5, máximo 5.0, media 3.53, desviación estándar 0.90.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Variable numérica que se compara entre grupos (promedios, violines y mapa de calor) y que se interpreta con IA.

6. Ruta Experto: `experto.csv`

Archivo: `experto.csv` (200 filas, 12 variables). **Enfoque:** diagnóstico y limpieza de datos, y análisis de todas las variables. Este archivo contiene ruido intencional (ver la sección 9).

Resumen de variables

Variable	Tipo	Valores o rango
<code>id_estudiante</code>	Identificador	E001 a E200
<code>facultad</code>	Categórica nominal	4 categorías
<code>horario_estudio</code>	Categórica nominal	Mañana, Tarde, Noche
<code>participacion_clase</code>	Categórica ordinal	Nula, Baja, Media, Alta (en ese orden)
<code>asistencia_pct</code>	Numérica continua	0 a 100 (porcentaje)
<code>horas_biblioteca_virtual</code>	Numérica continua	0 a 30 horas
<code>clics_material_extra</code>	Numérica discreta	0 a 50 clics
<code>uso_tutorias</code>	Categórica binaria	Sí, No
<code>nota_corte1</code>	Numérica continua	0.0 a 5.0
<code>nota_corte2</code>	Numérica continua	0.0 a 5.0
<code>nota_final</code>	Numérica continua	0.0 a 5.0
<code>comentario_retro</code>	Texto libre	Texto breve

Fichas de variables

<code>id_estudiante</code>	Identificador del estudiante
Significado	Código único que identifica cada registro del conjunto de datos. No contiene información personal.
Tipo	Identificador (texto).
Valores válidos	Código de la forma E seguido de tres dígitos, de E001 a E200.
Valores observados	200 valores distintos; ninguno se repite.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Permite identificar cada fila. No se analiza ni se grafica.

facultad	Facultad del estudiante
Significado	Área académica a la que pertenece el estudiante.
Tipo	Categórica nominal (texto).
Valores válidos	Ingeniería, Salud, Humanidades, Matemáticas.
Valores observados	50 registros por facultad.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Categoría para comparar grupos y para desagregar resultados por subgrupos. Se cruza con <code>uso_tutorias</code> .

horario_estudio	Horario de estudio preferido
Significado	Franja del día en la que el estudiante declara estudiar con mayor frecuencia.
Tipo	Categórica nominal (texto). Las categorías tienen un orden cronológico natural que la app usa solo para ordenar tablas y gráficas.
Valores válidos	Mañana, Tarde, Noche.
Valores observados	Mañana: 79, Tarde: 72, Noche: 49 registros.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Categoría adicional para cruces y para colorear la matriz de dispersión.

participacion_clase	Nivel de participación en clase
Significado	Valoración del nivel de intervención del estudiante en las sesiones de clase.
Tipo	Categórica ordinal (texto): las categorías tienen un orden lógico.
Valores válidos	Nula, Baja, Media, Alta (de menor a mayor participación).
Valores observados	Nula: 38, Baja: 41, Media: 69, Alta: 52 registros.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Categoría ordinal adicional para cruces y comparaciones.

asistencia_pct	Porcentaje de asistencia
Significado	Porcentaje de las sesiones programadas a las que asistió el estudiante.
Tipo	Numérica continua.
Valores válidos	Porcentaje de 0 a 100, con un decimal.
Valores observados	Mínimo 42.4, máximo 100.0, media 77.24.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Variable numérica para el diagnóstico: atípicos, sesgo y correlaciones (Pearson y Spearman).

horas_biblioteca_virtual	Horas en la biblioteca virtual
Significado	Horas acumuladas de consulta de recursos de la biblioteca virtual durante el periodo.
Tipo	Numérica continua.
Valores válidos	Horas, de 0 a 30 (valores declarados), con un decimal.
Valores observados	Mínimo 0.0, máximo 25.3, media 9.85 (dataset maestro).
Valores vacíos	No en el dataset maestro. En <code>experto.csv</code> algunas celdas están vacías de forma intencional.
Uso en esta ruta	Contiene celdas vacías. Se detectan en la sub-pestaña Calidad y se tratan con la <i>Limpieza rápida</i> (relleno con la mediana) o con código propio.

clics_material_extra	Clics en material complementario
Significado	Número de veces que el estudiante abrió material complementario en la plataforma.
Tipo	Numérica discreta (conteo). En el archivo se guarda con formato decimal, por ejemplo 29.0.
Valores válidos	Números enteros de 0 a 50.
Valores observados	Mínimo 0, máximo 50, media 19.52.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Variable numérica para el diagnóstico y las correlaciones.

uso_tutorias	Uso de tutorías
Significado	Indica si el estudiante utilizó el servicio de tutorías durante el semestre.
Tipo	Categórica binaria (texto).
Valores válidos	Sí, No.
Valores observados	No: 130, Sí: 70 registros.
Valores vacíos	No admite vacíos.
Uso en esta ruta	Categoría binaria para comparar a quienes usaron y no usaron tutorías. Se analiza sola y combinada con otras categorías.

nota_corte1		Nota del primer corte
Significado	Calificación obtenida en el primer corte evaluativo del semestre.	
Tipo	Numérica continua.	
Valores válidos	Escala de 0.0 a 5.0, con un decimal.	
Valores observados	Mínimo 1.5, máximo 5.0, media 3.53 (dataset maestro).	
Valores vacíos	No en el dataset maestro. En <code>experto.csv</code> algunos valores están escritos como texto (por ejemplo, <i>Tres</i>) de forma intencional.	
Uso en esta ruta	Contiene valores escritos como texto. La app la detecta como <i>número con texto mezclado</i> ; se corrige con la <i>Limpieza rápida</i> .	

nota_corte2		Nota del segundo corte
Significado	Calificación obtenida en el segundo corte evaluativo del semestre.	
Tipo	Numérica continua.	
Valores válidos	Escala de 0.0 a 5.0, con un decimal.	
Valores observados	Mínimo 1.3, máximo 5.0, media 3.53.	
Valores vacíos	No admite vacíos.	
Uso en esta ruta	Segunda nota parcial. Junto con <code>nota_corte1</code> permite comprobar cómo se compone <code>nota_final</code> .	

nota_final		Nota final
Significado	Calificación definitiva del estudiante. Se calcula como el promedio de <code>nota_corte1</code> y <code>nota_corte2</code> , redondeado a un decimal.	
Tipo	Numérica continua.	
Valores válidos	Escala de 0.0 a 5.0, con un decimal.	
Valores observados	Mínimo 1.5, máximo 5.0, media 3.53, desviación estándar 0.90.	
Valores vacíos	No admite vacíos.	
Uso en esta ruta	Variable objetivo: es la que se compara entre grupos, se desagrega y se interpreta con IA.	

comentario_retro		Comentario de retroalimentación
Significado	Texto breve escrito por el estudiante, a mitad de semestre, sobre su experiencia en la materia.	
Tipo	Texto libre (español).	
Valores válidos	Cualquier texto breve.	
Valores observados	Entre 50 y 92 caracteres (promedio 66). Hay 39 textos distintos en 200 registros: algunos comentarios se repiten.	
Valores vacíos	No admite vacíos.	
Uso en esta ruta	Texto libre para el análisis cualitativo complementario (palabras frecuentes y palabras clave).	

7. Estadísticos de referencia

Los valores de esta sección se calcularon sobre el dataset maestro (`maestro.csv`, 200 registros). Las columnas que comparten los demás archivos tienen los mismos valores.

7.1. Variables numéricas

Variable	n	Mínimo	Máximo	Media	Desv. est.
<code>asistencia_pct</code>	200	42.4	100.0	77.24	11.68
<code>horas_biblioteca_virtual</code>	200	0.0	25.3	9.85	5.94
<code>clics_material_extra</code>	200	0.0	50.0	19.52	9.53
<code>nota_corte1</code>	200	1.5	5.0	3.53	0.90
<code>nota_corte2</code>	200	1.3	5.0	3.53	0.93
<code>nota_final</code>	200	1.5	5.0	3.53	0.90

7.2. Variables categóricas

Variable	Categoría	Registros	Porcentaje
<code>facultad</code>	Ingeniería	50	25.0 %
	Salud	50	25.0 %
	Humanidades	50	25.0 %
	Matemáticas	50	25.0 %
<code>horario_estudio</code>	Mañana	79	39.5 %
	Tarde	72	36.0 %
	Noche	49	24.5 %
<code>participacion_clase</code>	Nula	38	19.0 %
	Baja	41	20.5 %
	Media	69	34.5 %
	Alta	52	26.0 %
<code>uso_tutorias</code>	Sí	70	35.0 %
	No	130	65.0 %

8. Reglas de coherencia entre variables

Estas reglas se cumplen en todos los registros del dataset maestro:

- R1.** `id_estudiante` es único: no hay dos filas con el mismo código.
- R2.** `nota_final` es el promedio de `nota_corte1` y `nota_corte2`, redondeado a un decimal.
- R3.** Todas las notas están entre 0.0 y 5.0.
- R4.** `asistencia_pct` está entre 0 y 100.
- R5.** Las variables categóricas solo toman los valores listados en sus fichas.
- R6.** Cada facultad tiene exactamente 50 registros.

9. Calidad de los datos y ruido intencional

Archivo	Estado de los datos	Qué hacer
maestro.csv	Sin celdas vacías ni valores fuera de rango.	Usarlo como referencia.
basico.csv	Sin celdas vacías.	Analizar directamente.
medio.csv	Sin celdas vacías.	Analizar directamente.
experto.csv	Contiene ruido intencional en dos columnas (ver abajo).	Diagnosticar, limpiar y luego analizar.

9.1. Ruido intencional en `experto.csv`

Para practicar la limpieza de datos, este archivo se alteró de forma deliberada:

- `horas_biblioteca_virtual`: algunas celdas están vacías.
- `nota_corte1`: unos pocos valores están escritos con letras (por ejemplo, *Tres*) en lugar de números; por eso la columna se lee como texto.

En la app, la sub-pestaña *Calidad* de *2 · EDA estándar* muestra estos problemas. La casilla *Limpieza rápida* de la pestaña *1 · Carga de datos* los corrige: convierte a número lo que pueda (lo que no se puede convertir queda vacío) y rellena los vacíos numéricos con la mediana de la columna.

Para pensar

Rellenar con la mediana es una decisión de análisis, no un hecho neutral: conserva el número de filas, pero puede suavizar la variabilidad real. Eliminar las filas con vacíos es otra opción, con otras consecuencias.

10. Cómo clasifica la app cada variable

Al cargar un archivo, la app clasifica automáticamente cada columna. Esa clasificación decide qué gráficas y análisis se ofrecen para ella.

Criterios de la clasificación:

- **Número**: la columna ya es numérica.
- **Número con texto mezclado**: no es numérica, pero al menos el 90 % de sus valores se pueden convertir a número.
- **Identificador**: todos los valores son distintos y son textos cortos.
- **Texto libre**: textos de 40 caracteres o más en promedio.
- **Categoría**: el resto de columnas de texto; se grafican si tienen hasta 25 categorías distintas.

La tabla siguiente muestra el resultado para cada variable:

Variable	maestro, medio	basico, experto (sin limpiar)	experto (Limpieza rápida)
id_estudiante	Identificador	Identificador	Identificador
facultad	Categoría	Categoría	Categoría
horario_estudio	Categoría	Categoría	Categoría
participacion_clase	Categoría	Categoría	Categoría
asistencia_pct	Número	Número	Número
horas_biblioteca_virtual	Número	Número	Número
clics_material_extra	Número	Número	Número
uso_tutorias	Categoría	Categoría	Categoría
nota_corte1	Número	Número con texto mezclado	Número
nota_corte2	Número	Número	Número
nota_final	Número	Número	Número
comentario_retro	Texto libre	Texto libre	Texto libre

11. Uso responsable de los datos

- Estos datos no corresponden a personas reales y pueden usarse libremente en el taller.
- Con datos reales de estudiantes, anonimice antes de analizar: quite nombres, documentos, correos y cualquier dato que permita identificar a una persona.
- No suba datos reales identificables a herramientas de IA públicas. Verifique primero la política de privacidad de la herramienta y las normas de su institución.
- La API Key de Groq es personal: no la escriba en el código ni la comparta en canales grupales.
- Las respuestas de la IA son una interpretación, no un resultado verificado. Contrástelas con las tablas y gráficas de la app antes de tomar decisiones.

A. Registro de ejemplo

Una fila completa del dataset maestro (`id_estudiante = E096`):

Variable	Valor
id_estudiante	E096
facultad	Salud
horario_estudio	Tarde
participacion_clase	Alta
asistencia_pct	95.2
horas_biblioteca_virtual	13.8
clics_material_extra	29.0
uso_tutorias	No
nota_corte1	3.2
nota_corte2	3.5
nota_final	3.4
comentario_retro	Me gustaron mucho las lecturas propuestas durante el semestre.

B. Glosario

Registro

Cada fila del archivo; en este dataset, un estudiante.

Variable

Cada columna del archivo; una característica que se mide o se registra.

Variable objetivo

La variable que se quiere describir o explicar; en este taller, `nota_final`.

Variable de agrupación

Categoría que se usa para dividir los registros en grupos y comparar (por ejemplo, `facultad`).

Valor vacío

Celda sin dato. También se le llama valor faltante o nulo.

Valor atípico

Valor muy alejado del resto. La app usa la regla del rango intercuartil: por debajo de $Q_1 - 1.5 \text{ RIC}$ o por encima de $Q_3 + 1.5 \text{ RIC}$.

Mediana

Valor central de una variable ordenada; es menos sensible a valores extremos que el promedio.

Sesgo

Medida de la asimetría de una distribución. Cerca de 0 indica una distribución simétrica.

Correlación

Medida de qué tan juntas varían dos variables numéricas, entre -1 y 1 . *Pearson* mide relaciones lineales; *Spearman* trabaja con los rangos de los valores.

Desagregar

Dividir un resultado global en subgrupos para revisarlos por separado.

EDA Análisis exploratorio de datos: revisar calidad, distribuciones y relaciones antes de concluir.

Imputación

Rellenar valores vacíos con un valor estimado, como la mediana.

Texto libre

Texto escrito sin categorías predefinidas; se analiza con frecuencias de palabras o con IA.

C. Autoría y contacto

Jorge Iván Padilla Buriticá

Correo: jipadillab@eafit.edu.co

LinkedIn: [linkedin.com/in/jipadilla](https://www.linkedin.com/in/jipadilla)

Repositorio: github.com/jipadillab/Trayectoria_IA_EAFIT